

Pt 2.1 Introducción a Aplicaciones LLM con LangChain

Instrucciones

Esta tarea puede completarse de forma individual o en parejas. Todas las tareas requeridas deben completarse. Las tareas opcionales proporcionan profundidad adicional para estudiantes motivados.

Objetivos

- Introducción a los fundamentos teóricos de las aplicaciones basadas en LLM.
- Comprensión de los patrones básicos de flujo de trabajo y su aplicación en escenarios del mundo real.
- Implementación de chatbots simples y aplicaciones LLM utilizando patrones básicos de flujo de trabajo.

Parte I. Fundamentos Teóricos

1. Modelos Sin Razonamiento vs. Modelos con Razonamiento

Investiga y explica las diferencias conceptuales entre los LLM sin razonamiento y con razonamiento. Incluye:

- Las principales distinciones
- Casos de uso típicos
- Implicaciones para el diseño de aplicaciones basadas en LLM

2. Técnicas de Prompting para Aplicaciones No Agénticas

Realiza una investigación sobre técnicas fundamentales de prompting para aplicaciones que no emplean arquitecturas basadas en agentes. Puedes usar el siguiente recurso como primera lectura (sección de conceptos básicos, desde Introducción a la Ingeniería de Prompts):

https://learnprompting.org/docs/basics/prompt_engineering

Escribe (y comprende) una breve explicación que cubra:

1. **Estrategias básicas de prompting** relevantes para aplicaciones no agénticas (por ejemplo, prompts de instrucción, zero-shot, few-shot, prompts con formato restringido).

2. **El propósito de estas estrategias** - Explica brevemente qué intenta lograr cada técnica.
3. **Recomendaciones** - Mejores prácticas generales para el diseño de prompts.

Parte II. Tareas de Desarrollo

3. Chatbot Basado en Consola con Memoria

Desarrolla un chatbot simple basado en consola usando **LangChain**.

Requisitos:

- Implementar memoria usando una estructura básica (por ejemplo, una lista de Python)
- Soportar conversación de múltiples turnos
- Asegurar que el código sea claro, funcional y mínimamente documentado

4. Patrones de Flujo de Trabajo

Lee el artículo (solo la introducción y los tres patrones de flujo de trabajo):

<https://www.philschmid.de/agent-ic-pattern>

El artículo presenta **tres patrones básicos de flujo de trabajo** para aplicaciones LLM:

- **Flujo de trabajo: Encadenamiento de Prompts** (Prompt Chaining)
- **Flujo de trabajo: Enrutamiento** (Routing)
- **Flujo de trabajo: Paralelización** (Parallelization)

En este ejercicio debes adaptar los tres ejemplos de patrones de flujo de trabajo del artículo a LangChain.

Requisitos:

- Reimplementar cada patrón usando `init_chat_model` de LangChain
- Preservar el comportamiento y la lógica previstos
- Verificar que el código se ejecute correctamente
- No necesitas entregar estas implementaciones, pero las necesitarás más adelante para el ejercicio 5

5. Mini Aplicaciones Basadas en Patrones de Flujo de Trabajo

Elige al menos **dos patrones de flujo de trabajo** del Ejercicio 4, construye una pequeña aplicación LLM para cada patrón usando LangChain.

Requisitos:

- No reutilizar escenarios del artículo
- Cada mini aplicación debe ilustrar claramente el patrón seleccionado
- Proporcionar una breve explicación de tus decisiones de diseño y cómo se aplica el patrón

Requisito Adicional: Seguimiento del Uso de Tokens

Comprender y rastrear el consumo de tokens es una práctica esencial al desarrollar aplicaciones LLM del mundo real. Diferentes modelos y proveedores aplican precios basados en tokens de entrada, salida y razonamiento; por lo tanto, monitorear el uso de tokens ayuda a los desarrolladores a tomar decisiones informadas sobre optimización de costos, selección de modelos, diseño de prompts y escalabilidad del sistema.

Para cada mini aplicación, implementa un mecanismo simple para rastrear el uso de tokens a lo largo de todo el pipeline. El seguimiento debe incluir:

- input_tokens
- output_tokens
- reasoning_tokens (si está disponible desde el modelo o proveedor)

Puedes implementar esto con cualquier estructura básica (por ejemplo, un diccionario de Python, dataclass o un objeto simple). Al final de cada interacción del usuario o ejecución del pipeline, muestra el total de tokens utilizados.

6. Aplicación Combinada Multi-Patrón con Streamlit

Desarrolla una aplicación LLM completa integrando **al menos dos patrones de flujo de trabajo** usando LangChain y Streamlit.

Requisitos:

- Incluir un mecanismo de memoria simple
- Primero, implementar una aplicación de consola simple
- Implementar una aplicación streamlit simple, solo un archivo. Pasaremos a mejores arquitecturas más adelante en este curso
- Documentar las decisiones de diseño y explicar cómo se integra cada patrón

Requisito Adicional: Seguimiento del Uso de Tokens

La aplicación debe incluir un mecanismo para rastrear el uso global de tokens a través de toda la sesión del usuario o pipeline. Rastrea y muestra al menos:

- input_tokens
- output_tokens
- reasoning_tokens (si está disponible desde el modelo o proveedor)

Al final de cada interacción del usuario o ejecución del pipeline, muestra el total de tokens utilizados.

7. Investigación sobre Técnicas de Evaluación de LLM (opcional)

Realiza una breve investigación sobre técnicas de evaluación para aplicaciones basadas en LLM.

Aspectos recomendados:

- Métodos de evaluación automatizada
- Estrategias de evaluación dirigidas por humanos
- Fortalezas y debilidades de cada una
- Casos de uso apropiados para cada método

Entregables

1. **Un informe escrito** incluyendo todas las explicaciones teóricas y justificaciones de diseño (ver descripción abajo).
2. **Código fuente** para todas las implementaciones (proyecto de PyCharm):
 - Ejercicio 3: chatbot.py
 - Ejercicio 5: workflow_patterns_chains.py, workflow_patterns_router.py, workflow_patterns_parallelization.py
 - Ejercicio 6: app.py, gui_app.py

Informe Final

Secciones:

1. Identificación de los Miembros del Equipo

- Nombres completos de todos los miembros (individual o pareja).
- Breve descripción de cómo se distribuyó el trabajo.

2. Respuestas a las Preguntas Teóricas

- Respuestas completas y claramente escritas para todos los ejercicios de la Parte I.

3. Documentación de la Implementación - Para cada ejercicio de la Parte II, incluir:

- Una breve descripción de la aplicación desarrollada.
- Decisiones de diseño tomadas durante la implementación y justificación de cada decisión.
- Dificultades encontradas y cómo se resolvieron.
- Descripción de las contribuciones de cada miembro.

4. Discusión sobre el Uso de Tokens (donde se requiera)

- Explicar el mecanismo de seguimiento de tokens implementado.
- Resumir los resultados e insights obtenidos del seguimiento del uso.

5. Referencias

- Listar todas las fuentes externas utilizadas (artículos, documentación, tutoriales, etc.).

Calificación

- Ejercicios 1-2 (teoría): **10%**
- Ejercicio 3 (chatbot simple de consola): **10%**
- Ejercicio 5 (mini apps de patrones de flujo de trabajo): **20%**

- Ejercicio 6 (aplicación final): **50%**
- Informe Final: **10%**